

Anexo Matemático: Formalización de la Inferencia Axiomática

Este documento proporciona el rigor matemático necesario para explicar por qué el anclaje de "Verdades de Dominio" es superior al aprendizaje inductivo puro.

1. Reducción de la Entropía mediante Priors de Dirac

En la inferencia Bayesiana tradicional, buscamos la distribución posterior $P(\theta|D)$:

$$P(\theta|D) = \frac{P(D|\theta)P(\theta)}{P(D)}$$

Donde θ son los parámetros del modelo y D los datos. En los LLM actuales, el prior $P(\theta)$ es difuso (casi plano), lo que obliga a procesar billones de D para ajustar θ .

Propuesta Axioma-Omega: Definimos el prior como una función delta de Dirac δ sobre leyes físicas conocidas $\mathcal{L}$:

$$P(\theta) = \delta(\theta - \mathcal{L})$$

Esto colapsa la entropía del sistema $H(X)$ de forma inmediata:

$$H(X|\mathcal{L}) = - \int p(x, \mathcal{L}) \ln p(x|\mathcal{L}) dx \approx 0$$

El modelo no "aprende" la ley; la ley es una precondition de existencia.

2. Restricciones en la Variedad (Manifold Constraints)

Los datos de "mundo" habitan en un espacio de alta dimensión $\mathbb{R}^N$. Sin embargo, los

fenómenos físicos reales viven en una sub-variedad de dimensión mucho menor $\mathcal{M} \subset \mathbb{R}^N$.

Actualmente, la IA gasta cómputo intentando encontrar $\mathcal{M}$. Nosotros definimos $\mathcal{M}$ mediante ecuaciones diferenciales:

$$\mathcal{F}(u, \nabla u, \nabla^2 u, \dots; \mathbf{x}) = 0$$

Al obligar al optimizador a permanecer en $\mathcal{M}$, el volumen del espacio de búsqueda V se reduce exponencialmente:

$$V_{red} = V_{orig} \cdot \left(\frac{\epsilon}{L}\right)^{d-k}$$

Donde d es la dimensión original y k son los grados de libertad eliminados por los axiomas.

3. Función de Pérdida Informada por la Física (PINNs)

Para integrar esto en redes neuronales actuales, modificamos la función de pérdida L_{total} :

$$L_{total} = w_{data} L_{data} + w_{phys} L_{phys}$$

Donde L_{phys} penaliza cualquier salida que viole leyes como la conservación de la energía:

$$L_{phys} = \frac{1}{N} \sum_{i=1}^N \|\mathcal{N}[u(\mathbf{x}_i)] - f(\mathbf{x}_i)\|^2$$

Aquí, $\mathcal{N}$ es un operador diferencial que representa la "Verdad de Dominio".

4. Directrices para la Implementación Informática

1. **Capas de Proyección Lineal:** Insertar capas al final del modelo que proyecten el espacio

latente sobre el espacio de soluciones físicamente válidas (Orthogonal Projection).

2. **Simbólico-Diferenciable:** Usar librerías como *PyTorch* o *JAX* para integrar motores de álgebra simbólica que verifiquen las "Anclas" en tiempo de ejecución.

3. **Memoria de Estado Diferencial:** Almacenar solo el residuo $R = D_{real} - D_{simulado}$.
Si el axioma explica el 99% del movimiento, solo guardamos el 1% de variación.